

Enhancing Turkish Retrieval Performance with “bge-m3”

Collective Learning Class, Prof. Mehmet Fatih AMASYALI
Zainab Elfatih Mohamed Malik, 24501096

I. OVERVIEW

This project aims to improve Turkish retrieval performance by fine-tuning the bi-directional global embedding bge-m3 model on the WikiRAG-TR dataset. The dataset contains 1000 questions, each paired with 5 chunks (1 correct and 4 incorrect), resulting in 5000 chunks to be stored in a vector database. The retrieval performance of the original and fine-tuned models will be evaluated using Top-1 and Top-5 accuracy on the same set of 1000 questions, demonstrating the potential of fine-tuning for better Turkish information retrieval.

II. METHODOLOGY

A. Dataset Overview and Preprocessing

WikiRAG-TR dataset consists of 5999 rows and includes various fields to facilitate information retrieval evaluation. Each row represents a question-answer-context triplet, with additional metadata. Key columns include:

- **id:** A unique identifier for each question.
- **question:** The query posed in Turkish.
- **answer:** The correct response to the question.
- **context:** The passage from which the correct answer can be derived.
- **is_negative_response:** A binary indicator where `0` represents a positive response, and `1` represents a negative one.
- **number_of_articles:** The total number of articles considered in the context.
- **ctx_split_points:** A list of character positions indicating splits in the context text.
- **correct_intro_idx:** The index pointing to the correct introduction segment within the split context.

The dataset consists of 1000 questions, each accompanied by 5 chunks: 1 correct chunk relevant to the question and 4 incorrect chunks serving as distractors, resulting in a total of 5000 chunks (1000 questions $\times$ 5 chunks). After processing, each entry should have:

- question,
- Chunk (one of the 5 chunks),
- label (True or False).

	id	question	answer	context	is_negative_response	number_of_articles	ctx_split_points	correct_intro_idx
0	fdb9e733-8b3f-430e-93d4-72c563f2d00c	Bermuda Adaları'nın Birleşik Krallık'a bağlı b...	Bermuda Adaları, 1609 yılında İngiliz denizci ...	Thingspiel (çoğulu Thingspiele), 1930'larda sa...	0	6	[374, 1916, 3860, 4309, 4775, 5443]	3
1	cb5dadcf-cb15-49c5-b0a5-8de9bb77cb48	.bm uzantısının kullanımı ne zaman başladı?	.bm uzantısı 2007 yılında kullanıma açıldı.	Kabulgan – Türk, Altay ve Moğol mitolojisinde ...	0	2	[266, 398]	1
2	0b827c00-160b-4a1c-9e8f-096208a73892	NKVD'nin Sovyetler Birliği içindeki siyasi bas...	NKVD, Joseph Stalin yönetimindeki Büyük Temizl...	NKVD (Narodnyy komissariat vnutrennih del) (...)	0	3	[1973, 3027, 3095]	0
3	0fb1e793-3744-4b29-ba49-cdec7fb6cd2	Blohin'in Stalin rejimi sırasında infazları ge...	Vasili Blohin, Stalin rejimi sırasında infazla...	1973 yılında imzalanan 1978 yılında değiştiril...	0	6	[825, 968, 1319, 1532, 2303, 2884]	4
4	764a2ff0-053e-49e1-8274-a5dee96f0392	Cengel Operasyonu'nun amacı neydi?	Cengel Operasyonu, Soğuk Savaş sırasında İngil...	Waffenamt (WaA) Alman Ordusu Silah Ajansı idi...	0	3	[1949, 2321, 3138]	2
...	...	...	...	...	...	...	...	...

question	chunk	is_correct
Bermuda Adaları'nın Birleşik Krallık'a bağlı b...	Bermuda, tam adıyla Bermuda Adaları (diğer adı...	True
Bermuda Adaları'nın Birleşik Krallık'a bağlı b...	American Horror Story: Asylum (Türkçesi: Ameri...	False
Bermuda Adaları'nın Birleşik Krallık'a bağlı b...	TARDIS (Time And Relative Dimension In Space) ...	False
Bermuda Adaları'nın Birleşik Krallık'a bağlı b...	Thingspiel (çoğulu Thingspiele), 1930'larda sa...	False
Bermuda Adaları'nın Birleşik Krallık'a bağlı b...	Yoshiwara (Japonca: 吉原), Japonya'da Edo'da bul...	False

Fig. 1: Dataset DataFrame

B. Generate Embedding Using bge-m3

Embeddings play a crucial role in modern information retrieval systems by transforming text data into dense numerical vectors that capture the semantic meaning of the text. This representation allows for efficient similarity-based retrieval, enabling systems to quickly find the most relevant chunks of information in response to a query.




Fig. 2: Embedding process

There are various embedding models available, each with unique features and strengths. Some embeddings are designed for general-purpose semantic understanding, while others specialize in specific tasks like question answering or document summarization.

In this project, bge-m3 model, known for its strong performance in creating high-quality embeddings for retrieval and semantic similarity tasks. The steps done are:

- Embedding the Chunks:
 - The dataset contains 5,000 chunks (1 correct and 4 distractors per question). Each chunk is processed using the E5 model to generate a fixed-size dense vector.

- Storing in a Vector Database:

- The embeddings, along with metadata (e.g., question ID, chunk text), are stored in a vector database. FAISS vector database have been used. it enables fast and efficient similarity-based searches among embeddings.

C. Retrieval Evaluation

The retrieval evaluation process is designed to assess the performance of a retrieval system by testing it on a dataset of questions and their corresponding correct chunks. The system retrieves the top `k` most similar chunks for each question and evaluates whether the correct chunk is ranked as the top result (top-1) or appears within the top five results (top-5). Throughout this process, the system tracks the number of correct top-1 and top-5 results, recording examples of both correct and incorrect retrievals. Once the evaluation is complete, the system calculates the accuracy for both top-1 and top-5 results.

```
# test retrieval function
sample_query = "Bermuda Adaları hakkında bilgi verin."
results, distances = retrieve_similar_chunks(
    sample_query, tokenizer, model, index, embeddings_df, top_k=5)

print("Top-5 Retrieved Chunks:")
for i, (chunk, dist) in enumerate(zip(results["chunk"], distances)):
    print(f"{i + 1}. Distance: {dist:.4f}, Chunk: {chunk}")
```

Top-5 Retrieved Chunks:

1. Distance: 265.9328, Chunk: Sinop Tersanesi, Osmanlı İmparatorluğu'
2. Distance: 295.1357, Chunk: Bermuda, tam adıyla Bermuda Adaları (di
Toplam yüzölçümü 53,3 km²'dir. Başkenti Hamilton'dur, nüfus 65.000 ci
3. Distance: 297.3138, Chunk: Ford Prefect, Otostopçunun Galaksi Reht
4. Distance: 308.5385, Chunk: Hawaii dini, Yerli Hawaililerin yerli c
5. Distance: 330.0891, Chunk: Stalag V-A, II. Dünya Savaşı sırasında

Fig. 3: Retrieval sample with distance

D. Training and Fine-Tuning the Classification Model

The classifier model and fine-tuning process aim to evaluate and enhance the retrieval performance of the bge-m3 model. As seen in fig 4.

1. The pre-trained e5 model was tested to establish a baseline performance. In this step, the 1000 test questions are embedded using the pre-trained bge-m3 model, and the resulting embeddings are queried in the vector database to retrieve the top results.
2. The top 1 and top 5 results are evaluated based on how often the correct chunk appears in these rankings, and two accuracy metrics are recorded: Top-1 accuracy,

which measures the percentage of questions where the correct chunk is ranked first, and Top-5 accuracy, which measures the percentage of questions where the correct chunk appears among the top 5 retrieved results.

3. After testing the original model, the next step involves train and fine tune the e5 model to improve its performance. Data divided for 80/20 for training/validation. The same 1000 test questions are embedded again, this time using the fine-tuned model, and the retrieval process is repeated to measure improvements in accuracy.
4. The same Top-1 and Top-5 accuracy metrics are recorded and compared to the results from the original model. Fine-tuning is done using a dataset of question-chunk-label pairs, where the model learns to associate a question with its correct chunk. The training objective during fine-tuning is to minimize the error in retrieving the correct chunk for each question.
5. The hyperparameters used in the training process are configured to optimize the fine-tuning of the model. The `Training Arguments` include settings such as a learning rate, batch size for both training and evaluation, and training epochs. The model is evaluated at the end of each epoch, and logging is set up to report every 5 steps as beginning.




Fig. 4: Procedures flow chart

III. RESULTS

The bge-m3 model was evaluated in two main phases: using the pre-trained model and through subsequent training and fine-tuning. The performance of each approach is summarized below.

A. Pre-trained bge-m3 model

The pre-trained version of the bge-m3 model was directly evaluated without additional training or fine-tuning. It achieved the following results:

Top_1 accuracy	18%
Top_5 accuracy	20%

While these results are low, they serve as a baseline for comparison against trained and fine-tuned versions.

B. Train bge-m3 model

To further improve performance, the trained model underwent fine-tuning under various configurations. Details are presented in Table 1.

Table 1: Trained and Fine-Tuned bge-m3 Model Details

#	epochs	Batches	Learning rate	Top1_acc (%)	Top5_acc (%)
Pre-Trained	-	-	-	18	20
Trained bge-m3	5	8	0.00005	30	100
Fine tuned1	5	32↑	0.00005	32	
Fine tuned2	5	32	0.001 ↑	37	
Fine tuned3	5	64 ↑	0.001	33	
Fine tuned4	5	8 ↓	0.001	59	
Fine tuned5	15 ↑	8	0.001	59	
Fine tuned6	30 ↑	8	0.001	59	

- Training Loss

Training loss for trained and fine-tuned models for the first 5 epochs ranged from 0.4-0.6 while for fine-tuned models with higher epochs numbers it bounced between 0.4-0.8.




Fig. 5a: Training loss for first 5 epochs




Fig. 5b: Training loss vs epochs (6-30)

• Samples of output:

Below are samples from the trained and fine-tuned models for a question example. For the trained model, due to its low accuracy, it failed to recognize the correct answer as the Top-1 suggestion, although the correct answer was included within the Top-5 results, but not as the first suggestion. In contrast, the fine-tuned model began to recognize the correct answer as the Top-1 suggestion but still missed it within the Top-5 results. The second fine-tuning successfully addressed this, correctly identifying the answer for both Top-1 and Top-5 rankings.

Trained

Query: Bermuda Adaları'nın Birleşik Krallık'a bağlı bir bölge olmasının tarihi sebepleri nelerdir?
Correct Answer: Bermuda, tam adıyla Bermuda Adaları (diğer adıyla Somers Adaları), Atlas Okyanusu'nda Toplam yüzölçümü 53,3 km²'dir. Başkenti Hamilton'dur, nüfus 65.000 civarındadır.

Retrieved Top-1: TARDIS (Time And Relative Dimension In Space) (Türkçe: Uzaydaki zaman ve izafi boyut) Asıl şekli olmasa da dışarıdan 1963 yılı Londrasından kalma bir polis telefon kulübesi olarak görülen Doktor onu çalmıştır ya da kendi söylediğine göre ödünç almıştır ve onunla birlikte son büyük zaman Doctor Who dizisi İngiltere'nin her yerine yayıldıktan sonra popüler kültür arasına girmeyi de başarmıştır. Kavramsal tarihi 1963'te Doctor Who dizisi yazılırken, yazar kişiler Doktor'un zaman makinesinin rüyası. Diğer Zaman Lordları TARDIS'in bir diğer adı olan TT Kapsülü yani Time Travel Capsule (Zaman Yolcu Kapsülü).

Retrieved Top-5:

1. TARDIS (Time And Relative Dimension In Space) (Türkçe: Uzaydaki zaman ve izafi boyut), İngiliz Asıl şekli olmasa da dışarıdan 1963 yılı Londrasından kalma bir polis telefon kulübesi olarak görülen Doktor onu çalmıştır ya da kendi söylediğine göre ödünç almıştır ve onunla birlikte son büyük zaman Doctor Who dizisi İngiltere'nin her yerine yayıldıktan sonra popüler kültür arasına girmeyi de başarmıştır. Kavramsal tarihi 1963'te Doctor Who dizisi yazılırken, yazar kişiler Doktor'un zaman makinesinin rüyası. Diğer Zaman Lordları TARDIS'in bir diğer adı olan TT Kapsülü yani Time Travel Capsule (Zaman Yolcu Kapsülü).

2. American Horror Story: Asylum (Türkçesi: Amerikan Korku Hikayesi: Akıl Hastanesi), FX tarafından 2016 yılında kurgusal bir akıl hastanesi olan Briarcliff Hastanesi'ndeki hastaların, görevlilerin ve diğer karakterlerin hikayeleri anlatılan bir televizyon dizisidir. İlk sezon gibi Asylum da eleştirmenlerden ve hayranlardan olumlu eleştiriler aldı. Jessica Lange'in Antoloji serisi olması dışında Lily Rabe, Naomi Grossman ve John Cromwell gibi bazı kadro oyuncular da dizide yer almıştır.

3. Thingspiel (çoğulu Thingspiele), 1930'larda savaş öncesi Nazi Almanyası'nda kısa süreli popüler bir oyun türüdür.

4. Yoshiwara (Japonca: 吉原), Japonya'da Edo'da bulunan bir yükaku idi. 1617'de kurulmuş olup Tokugawa Shogunluk tarafından, yeni zengin chōnin (tüccar) sınıflarının zevklerini azaltmak ve tecrit etmek için kurulmuştur.

5. Bermuda, tam adıyla Bermuda Adaları (diğer adıyla Somers Adaları), Atlas Okyanusu'nda, ABD'nin civarındadır. Toplam yüzölçümü 53,3 km²'dir. Başkenti Hamilton'dur, nüfus 65.000 civarındadır.

Fine-tuned 1

Query: Bermuda Adaları'nın Birleşik Krallık'a bağlı bir bölge olmasının tarihi sebepleri nelerdir?
Correct Answer: Bermuda, tam adıyla Bermuda Adaları (diğer adıyla Somers Adaları), Atlas Okyanusu'nda Toplam yüzölçümü 53,3 km²'dir. Başkenti Hamilton'dur, nüfus 65.000 civarındadır.

Retrieved Top-1: American Horror Story: Asylum (Türkçesi: Amerikan Korku Hikayesi: Akıl Hastanesi), FX tarafından 2016 yılında kurgusal bir akıl hastanesi olan Briarcliff Hastanesi'ndeki hastaların, görevlilerin ve diğer karakterlerin hikayeleri anlatılan bir televizyon dizisidir. İlk sezon gibi Asylum da eleştirmenlerden ve hayranlardan olumlu eleştiriler aldı. Jessica Lange'in, Antoloji serisi olması dışında Lily Rabe, Naomi Grossman ve John Cromwell gibi bazı kadro oyuncular da dizide yer almıştır.

Retrieved Top-5:

1. American Horror Story: Asylum (Türkçesi: Amerikan Korku Hikayesi: Akıl Hastanesi), FX tarafından 2016 yılında kurgusal bir akıl hastanesi olan Briarcliff Hastanesi'ndeki hastaların, görevlilerin ve diğer karakterlerin hikayeleri anlatılan bir televizyon dizisidir. İlk sezon gibi Asylum da eleştirmenlerden ve hayranlardan olumlu eleştiriler aldı. Jessica Lange'in, Antoloji serisi olması dışında Lily Rabe, Naomi Grossman ve John Cromwell gibi bazı kadro oyuncular da dizide yer almıştır.

2. Thingspiel (çoğulu Thingspiele), 1930'larda savaş öncesi Nazi Almanyası'nda kısa süreli popüler bir oyun türüdür.

3. TARDIS (Time And Relative Dimension In Space) (Türkçe: Uzaydaki zaman ve izafi boyut), İngiliz Asıl şekli olmasa da dışarıdan 1963 yılı Londrasından kalma bir polis telefon kulübesi olarak görülen Doktor onu çalmıştır ya da kendi söylediğine göre ödünç almıştır ve onunla birlikte son büyük zaman s Doctor Who dizisi İngiltere'nin her yerine yayıldıktan sonra popüler kültür arasına girmeyi de başarmıştır. Kavramsal tarihi 1963'te Doctor Who dizisi yazılırken, yazar kişiler Doktor'un zaman makinesinin neye rüyası. Diğer Zaman Lordları TARDIS'in bir diğer adı olan TT Kapsülü yani Time Travel Capsule (Zaman Yolculuğu Kapsülü).

4. Yoshiwara (Japonca: 吉原), Japonya'da Edo'da bulunan bir yükaku idi. 1617'de kurulmuş olup Tokugawa Shogunluk tarafından, yeni zengin chōnin (tüccar) sınıflarının zevklerini azaltmak ve tecrit etmek için kurulmuştur.

5. Bermuda, tam adıyla Bermuda Adaları (diğer adıyla Somers Adaları), Atlas Okyanusu'nda, ABD'nin civarındadır. Toplam yüzölçümü 53,3 km²'dir. Başkenti Hamilton'dur, nüfus 65.000 civarındadır.

Fine-tuned 2

Query: Bermuda Adaları'nın Birleşik Krallık'a bağlı bir bölge olmasının tarihi sebepleri nelerdir?
Correct Answer: Bermuda, tam adıyla Bermuda Adaları (diğer adıyla Somers Adaları), Atlas Okyanusu'nun toplam yüzölçümü 53,3 km²'dir. Başkenti Hamilton'dur, nüfus 65.000 civarındadır.

Retrieved Top-1: Bermuda, tam adıyla Bermuda Adaları (diğer adıyla Somers Adaları), Atlas Okyanusu'nun toplam yüzölçümü 53,3 km²'dir. Başkenti Hamilton'dur, nüfus 65.000 civarındadır.

Retrieved Top-5:

1. Bermuda, tam adıyla Bermuda Adaları (diğer adıyla Somers Adaları), Atlas Okyanusu'nda, ABD'nin toplam yüzölçümü 53,3 km²'dir. Başkenti Hamilton'dur, nüfus 65.000 civarındadır.

2. American Horror Story: Asylum (Türkçesi: Amerikan Korku Hikayesi: Akıl Hastanesi), FX tarafından 1964 yılında kurgusal bir akıl hastanesi olan Briarcliff Hastanesi'ndeki hastaların, görevli ilk sezon gibi Asylum da eleştirmenlerden ve hayranlardan olumlu eleştiriler aldı. Jessica Lange'in Antoloji serisi olması dışında Lily Rabe, Naomi Grossman ve John Cromwell gibi bazı kadro oyuncular

3. Thingspiel (çoğulu Thingspiele), 1930'larda savaş öncesi Nazi Almanyası'nda kısa süreli popüler

4. TARDIS (Time And Relative Dimension In Space) (Türkçe: Uzaydaki zaman ve izafi boyut), İngiliz Asıl şekli olmasa da dışarıdan 1963 yılı Londrasından kalma bir polis telefon kulübesi olarak görün Doktor onu çalmıştır ya da kendi söylediğine göre ödünç almıştır ve onunla birlikte son büyük zaman Doctor Who dizisi İngiltere'nin her yerine yayıldıktan sonra popüler kültür arasına girmeyi de başa Kavramsal tarihi 1963'te Doctor Who dizisi yazılırken, yazar kişiler Doktor'un zaman makinesinin ne Diğer Zaman Lordları TARDIS'in bir diğer adı olan TT Kapsülü yani Time Travel Capsule (Zaman Yolculuğu)

5. Yoshiwara (Japonca: 吉原), Japonya'da Edo'da bulunan bir yükaku idi. 1617'de kurulmuş olup Tokugawa tarafından, yeni zengin chōnin (tüccar) sınıflarının zevklerini azaltmak ve tecrit etmek için

C. Using Multilingual-e5-large-instruct model

The evaluation of the E5 model began with a smaller dataset due to its high computational requirements. Initially, a sample of 100 questions have been chosen, each accompanied by 5 answer chunks (1 correct and 4 distractors). The performance of the E5 model was evaluated across three stages: pre-trained, trained, and various fine-tuned configurations. The results are detailed in the table below

Table 1: Trained and Fine-Tuned multilingual-e5-large-instruct Model Details

#	epochs	Batches	Learning rate	Top1_acc (%)	Top5_acc (%)
Pre-Trained	-	-	-	7	11
Trained e5	5	8	0.00005	35	100
Fine tuned1	10↑	32↑	0.00005	49	
Fine tuned2	10	32	0.001 ↑	29	
Fine tuned3	15↑	64 ↑	0.00005↓	75	

IV. CONCLUSION

The bge-m3 model demonstrated substantial improvement through training and fine-tuning. The pre-trained model provided a baseline performance with Top-1 accuracy of 18% and Top-5 accuracy of 20%. After training and fine-tuning, the model's Top-1 accuracy reached 59%, a significant improvement. The best results were achieved with a smaller batch size of 8, a higher learning rate of 0.001, with 30 epochs. These findings highlight the effectiveness of fine-tuning and hyperparameter optimization in enhancing the performance of text embedding models for retrieval tasks.

The results also highlighted several key insights:

- The performance of the models is influenced by their underlying architecture.
- The e5 model, despite requiring longer processing time, demonstrated strong performance on smaller datasets, achieving 75% Top-1 accuracy and 100% for Top-5 after fine-tuning.
- The bge-m3 model, on the other hand, required more extensive fine-tuning but ended up with Top-1 accuracy of 59%.
- For the bge-m3 model, fine-tuning was essential but required careful adjustments of batch size and learning rate, as it was more sensitive to these hyperparameters.